



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

XÂY DỰNG MÔ HÌNH DỰ ĐOÁN MỨC ĐỘ THU HÚT CỦA VIDEO TRÊN MẠNG XÃ HỘI SỬ DỤNG KỸ THUẬT CHẤT LỌC TRI THỨC

*(Knowledge Distillation for Social Media Video Engagement
Prediction)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- TS. Lê Thanh Tùng (Khoa Công nghệ Thông tin)
- ThS. Văn Chí Nam (Khoa Công nghệ Thông tin)

[Nhóm] Sinh viên thực hiện:

1. Nguyễn Tuấn Công (MSSV: 22120039)
2. Trần Văn Anh Thư (MSSV: 22120357)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 07/2025 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

- **Nêu vấn đề:** Trong những năm gần đây, video ngắn trên các nền tảng mạng xã hội đã trở thành một trong những dạng nội dung phổ biến và có sức lan tỏa mạnh nhất. Đối với nhà sáng tạo nội dung, doanh nghiệp và các nền tảng số, việc ước lượng trước mức độ thu hút của video là một nhu cầu có ý nghĩa thực tiễn, vì nó có thể hỗ trợ quá trình lựa chọn, ưu tiên và tối ưu hóa nội dung trước khi phát hành. Tuy nhiên, mức độ tương tác của một video trên mạng xã hội không chỉ phụ thuộc vào nội dung mà còn chịu ảnh hưởng bởi nhiều yếu tố bên ngoài như thời điểm đăng tải, độ phổ biến của tài khoản, xu hướng xã hội và cơ chế phân phối của nền tảng. Do đó, trong phạm vi khóa luận này, bài toán được xác định là *dự đoán mức độ thu hút tương đối của video dựa trên tín hiệu nội dung đa phương thức*, thay vì mô hình hóa toàn bộ hành vi tương tác thực tế của người dùng.
- **Ý tưởng giải quyết:** Đề tài hướng đến xây dựng một hệ thống dự đoán điểm tương tác chuẩn hóa ECR (Engagement Continuation Rate) cho video ngắn bằng cách kết hợp thông tin hình ảnh/video, thông tin văn bản và các tín hiệu phụ về chất lượng thẩm mỹ/kỹ thuật. Để tận dụng sức mạnh của các mô hình tiền huấn luyện lớn nhưng vẫn đảm bảo khả năng triển khai thực tế, đề tài áp dụng hướng tiếp cận *Knowledge Distillation*. Cụ thể, các mô hình lớn đóng vai trò là các *teacher chuyên biệt* để tạo đặc trưng hoặc tín hiệu giám sát phụ; sau đó, một mô hình *student* gọn nhẹ được huấn luyện để học từ các tín hiệu này và thực hiện nhiệm vụ dự đoán ECR với chi phí suy luận thấp hơn.
- **Phương pháp giải quyết:**

Bước 1 - Teacher Ensemble: Sử dụng các mô hình tiền huấn luyện để trích

xuất đặc trưng đa phương thức từ video, bao gồm visual embedding từ ImageBind, điểm chất lượng thẩm mỹ/kỹ thuật từ MUSIQ và TOPIQ, caption tự động từ BLIP-2, và text embedding từ MiniLM sau khi kết hợp tiêu đề, mô tả và caption.

Bước 2 - Student Architecture: Thiết kế một mô hình student nhẹ với cơ chế *gated multimodal fusion*, có khả năng học cách kết hợp linh hoạt giữa đặc trưng visual và đặc trưng text trong cùng một không gian ẩn.

Bước 3 - Multi-task Distillation: Huấn luyện mô hình student trên nhiệm vụ chính là dự đoán ECR, đồng thời khai thác thêm các tín hiệu phụ như điểm aesthetic, điểm technical và độ tương đồng biểu diễn với teacher nhằm tăng chất lượng học biểu diễn.

Bước 4 - Explainability: Tích hợp cơ chế giải thích ở mức modality bằng phương pháp *ablation-based explanation*, thông qua việc lần lượt triệt tiêu từng nguồn đặc trưng và quan sát độ thay đổi của dự đoán.

- **Ý nghĩa thực tiễn:**

Cho nhà sáng tạo nội dung: Hệ thống có thể hỗ trợ đánh giá sơ bộ mức độ thu hút của video trước khi đăng tải, từ đó cung cấp thêm cơ sở tham khảo trong quá trình sản xuất nội dung.

Cho doanh nghiệp: Kết quả dự đoán có thể hỗ trợ việc sàng lọc hoặc ưu tiên các video marketing có tiềm năng tương tác tốt hơn.

Cho nghiên cứu kỹ thuật: Đề tài góp phần khảo sát khả năng áp dụng chất lọc tri thức cho bài toán hồi quy đa phương thức, đồng thời hướng đến một mô hình gọn nhẹ có thể triển khai thuận tiện hơn so với các mô hình tiền huấn lớn.

2.2 Mục tiêu đề tài

- **Mục tiêu tổng quát:** Xây dựng và đánh giá một mô hình học sâu gọn nhẹ có khả năng dự đoán điểm tương tác chuẩn hóa ECR của video ngắn trên mạng xã hội từ các tín hiệu đa phương thức, đồng thời khảo sát hiệu quả của kỹ thuật chất lọc tri thức trong việc giảm chi phí tính toán nhưng vẫn duy trì chất lượng dự đoán ở mức chấp nhận được.
- **Mục tiêu cụ thể:**
 - Xây dựng pipeline trích xuất đặc trưng đa phương thức từ video ngắn, bao gồm đặc trưng hình ảnh, đặc trưng văn bản và tín hiệu về chất lượng thẩm mỹ/kỹ thuật.
 - Thiết kế mô hình student nhẹ với cơ chế *gated multimodal fusion* để kết hợp đặc trưng visual và text trong bài toán dự đoán ECR.
 - Khảo sát hiệu quả của chiến lược huấn luyện đa nhiệm vụ, trong đó ngoài nhiệm vụ chính dự đoán ECR còn có các nhiệm vụ phụ liên quan đến quality scores và độ tương đồng biểu diễn với teacher.
 - Xây dựng cơ chế giải thích dự đoán ở mức modality nhằm phân tích mức đóng góp tương đối của đặc trưng hình ảnh và đặc trưng văn bản.
 - Đánh giá trade-off giữa độ chính xác dự đoán, số lượng tham số và tốc độ nội suy của mô hình student.
- **Câu hỏi nghiên cứu dự kiến:**
 - Việc sử dụng teacher ensemble để cung cấp đặc trưng và tín hiệu giám sát phụ có giúp cải thiện hiệu quả dự đoán ECR so với mô hình student chỉ học trực tiếp từ nhãn hay không?
 - Kiến trúc *gated multimodal fusion* có mang lại hiệu quả tốt hơn so với cách kết hợp đặc trưng đơn giản như *concatenation* hay không?

- Các tín hiệu chất lượng thẩm mỹ và kỹ thuật có hỗ trợ đáng kể cho nhiệm vụ dự đoán engagement hay chỉ đóng vai trò phụ trợ hạn chế?
- Cơ chế giải thích dựa trên ablation có giúp làm rõ mức độ đóng góp của từng modality trong dự đoán đầu ra hay không?

- **Giả thuyết nghiên cứu hướng đến kiểm chứng:**

- Mô hình student có tích hợp tín hiệu distillation và auxiliary tasks sẽ cho kết quả tốt hơn mô hình chỉ tối ưu trên nhãn ECR.
- Cơ chế gating giúp mô hình thích nghi tốt hơn với các video mà vai trò của visual và text là khác nhau.
- Việc bổ sung cơ chế giải thích ở mức modality có thể làm tăng giá trị phân tích của hệ thống mà không làm thay đổi đáng kể chi phí nội suy.

- **Ý nghĩa kỳ vọng của đề tài:**

- **Về mặt khoa học:** Góp phần khảo sát khả năng áp dụng knowledge distillation cho bài toán hồi quy đa phương thức; xây dựng thực nghiệm so sánh giữa các chiến lược fusion và các thành phần loss khác nhau.
- **Về mặt kỹ thuật:** Hình thành một pipeline hoàn chỉnh từ trích xuất đặc trưng, huấn luyện, đánh giá đến suy luận và sinh giải thích.
- **Về mặt ứng dụng:** Mục tiêu hướng đến là tạo ra một công cụ hỗ trợ đánh giá sơ bộ video trước khi đăng tải, với chi phí triển khai thấp hơn đáng kể so với các mô hình teacher lớn.

2.3 Phạm vi của đề tài

- **Nội dung nghiên cứu chính:**

- **Về mặt kỹ thuật:**

- * Xây dựng pipeline trích xuất đặc trưng từ các mô hình tiền huấn luyện cho từng modality. Đề tài ưu tiên sử dụng ImageBind cho nhánh vi-

sual, MUSIQ/TOPIQ cho nhánh quality, BLIP-2 cho nhánh caption và MiniLM cho nhánh text embedding. Các mô hình thay thế chỉ được xem xét khi phát sinh giới hạn về tài nguyên hoặc tương thích hệ thống.

- * Thiết kế và cài đặt mô hình student nhẹ với cơ chế *gated multimodal fusion*.
- * Khảo sát chiến lược huấn luyện đa nhiệm vụ kết hợp nhiệm vụ chính dự đoán ECR với các tín hiệu phụ về quality score và độ tương đồng biểu diễn.
- * Xây dựng cơ chế giải thích dự đoán ở mức modality thông qua phương pháp ablation.

– Về mặt dữ liệu:

- * Đề tài sử dụng bộ dữ liệu SnapUGC, bao gồm các video ngắn do người dùng tạo ra (UGC) được thu thập từ nền tảng thực tế, phục vụ cho bài toán dự đoán mức độ tương tác. Điểm đặc biệt của nghiên cứu này là việc không sử dụng các chỉ số truyền thống như số lượt xem, thời gian xem trung bình hay tỷ lệ lượt thích, do các chỉ số này thường không phản ánh đầy đủ sức hút thực sự của nội dung video ngắn. Hơn nữa, các nghiên cứu trước đây đã chỉ ra rằng điểm đánh giá chất lượng video (Mean Opinion Scores - MOS) không có sự tương quan mạnh mẽ với mức độ tương tác thực tế của người dùng.
- * Để giải quyết vấn đề này, đề tài sử dụng chỉ số ECR (Engagement Continuation Rate - Tỷ lệ tiếp tục tương tác) làm biến mục tiêu chính. ECR được thiết kế để đo lường khả năng giữ chân người xem của video, phản ánh chính xác mức độ hấp dẫn và khả năng duy trì sự chú ý của người dùng đối với nội dung. Việc sử dụng ECR kết hợp với bộ dữ liệu SnapUGC cho phép mô hình học sâu khai thác hiệu quả các đặc trưng đa phương thức (hình ảnh, âm thanh, văn bản), từ đó đưa ra các dự đoán chính xác hơn về mức độ thành công của video ngắn trên các nền

tăng mạng xã hội.

– **Về mặt hệ thống:**

- * Pipeline trích xuất đặc trưng chạy offline và lưu dữ liệu trung gian dưới dạng JSON hoặc định dạng tương đương.
- * Pipeline huấn luyện hỗ trợ lưu checkpoint và tiếp tục huấn luyện khi cần.
- * Xây dựng mô-đun suy luận phục vụ dự đoán trên video mới.
- * Mục tiêu hướng đến là xây dựng thêm một giao diện demo đơn giản để minh họa kết quả dự đoán và phân giải thích.

• **Đối tượng nghiên cứu:**

- Video ngắn trên mạng xã hội dưới góc nhìn nội dung đa phương thức.
- Các nguồn tín hiệu được sử dụng bao gồm hình ảnh/video, tiêu đề, mô tả và caption sinh tự động.
- Chỉ số nghiên cứu chính là ECR; các chỉ số quality score đóng vai trò tín hiệu phụ trong huấn luyện và phân tích.

• **Các giới hạn và ràng buộc:**

- **Giới hạn về bài toán:** Đề tài tập trung vào dự đoán engagement từ nội dung video và metadata đi kèm, chưa mô hình hóa các yếu tố ngoài nội dung như thời điểm đăng, độ phổ biến của tài khoản hay cơ chế phân phối của nền tảng.
- **Giới hạn về dữ liệu:** Thực nghiệm chủ yếu được tiến hành trên SnapUGC dataset, do đó khả năng tổng quát sang các nền tảng khác như TikTok, Instagram Reels hoặc YouTube Shorts cần được kiểm chứng thêm trong các nghiên cứu tiếp theo.
- **Giới hạn về kỹ thuật:** Teacher models yêu cầu GPU cho quá trình trích xuất đặc trưng; do đó toàn bộ pipeline không hướng đến xử lý end-to-end

theo thời gian thực.

- **Giới hạn về mô hình:** Student model tập trung vào dự đoán điểm ECR và phân tích mức đóng góp của các modality, chưa đưa ra khuyến nghị chỉnh sửa nội dung cụ thể cho người dùng.
- **Ràng buộc tài nguyên:** Quá trình huấn luyện và trích xuất đặc trưng chịu giới hạn bởi thời gian GPU, bộ nhớ và dung lượng lưu trữ hiện có; trong trường hợp cần thiết, có thể thực hiện một phần thực nghiệm trên tập con đại diện của bộ dữ liệu để phục vụ đánh giá phương pháp.

2.4 Cách tiếp cận dự kiến

1. Tổng quan các hướng nghiên cứu liên quan

Trong những năm gần đây, bài toán dự đoán mức độ thu hút hoặc mức độ tương tác của nội dung trên mạng xã hội thường được tiếp cận theo một số hướng chính. Thứ nhất, các phương pháp truyền thống sử dụng đặc trưng thủ công (*hand-crafted features*) kết hợp với các mô hình học máy cổ điển. Các phương pháp này có ưu điểm là đơn giản, nhưng thường gặp hạn chế khi xử lý dữ liệu đa phương thức và khó nắm bắt được các đặc trưng ngữ nghĩa mức cao của video. Thứ hai, các mô hình học sâu và mô hình tiền huấn luyện như CLIP, VideoMAE hoặc ImageBind cho khả năng biểu diễn mạnh, tuy nhiên chi phí tính toán lớn và khó triển khai trực tiếp trong bối cảnh tài nguyên hạn chế. Thứ ba, kỹ thuật knowledge distillation đã được chứng minh có hiệu quả trong việc chuyển giao tri thức từ mô hình lớn sang mô hình nhỏ ở nhiều bài toán thị giác máy tính và xử lý ngôn ngữ tự nhiên; tuy nhiên, việc áp dụng cho bài toán hồi quy đa phương thức như dự đoán engagement vẫn còn cần được khảo sát thêm.

Từ các hướng trên, đề tài lựa chọn một cách tiếp cận trung gian: tận dụng sức mạnh của các mô hình tiền huấn luyện để tạo đặc trưng và tín hiệu giám sát, sau đó huấn luyện một mô hình student nhẹ hơn cho nhiệm vụ dự đoán ECR. Cách

tiếp cận này nhằm cân bằng giữa độ chính xác dự đoán và khả năng triển khai thực tế.

2. Phương pháp và kiến trúc đề xuất (Distil-ShortVU)

Đề tài đề xuất một pipeline gồm bốn giai đoạn chính như sau:

1. Trích xuất đặc trưng đa phương thức bằng teacher ensemble

Thay vì sử dụng một teacher duy nhất cho toàn bộ bài toán, đề tài khai thác một tập hợp các mô hình chuyên biệt:

- *Visual teacher*: Sử dụng ImageBind để trích xuất vector biểu diễn hình ảnh từ một số khung hình được lấy mẫu trong video.
- *Quality teachers*: Sử dụng MUSIQ và TOPIQ để tạo các tín hiệu phụ phản ánh mức độ thẩm mỹ và chất lượng kỹ thuật của video.
- *Caption/Text teachers*: Sử dụng BLIP-2 để sinh caption từ khung hình đại diện, sau đó kết hợp với tiêu đề và mô tả để tạo biểu diễn văn bản thông qua MiniLM.

Trong phạm vi đề tài, các mô hình teacher này chủ yếu đóng vai trò tạo đặc trưng hoặc tín hiệu giám sát phụ, thay vì trực tiếp dự đoán ECR. Vì vậy, dạng chất lọc tri thức được nghiên cứu trong đề tài gần với *representation distillation* và *specialist-teacher distillation* hơn là knowledge distillation cổ điển trên logits.

2. Thiết kế mô hình student nhẹ cho bài toán dự đoán ECR

Mô hình student được thiết kế với mục tiêu giữ số lượng tham số ở mức thấp nhưng vẫn đủ khả năng biểu diễn. Hai nguồn đầu vào chính là visual embedding và text embedding được ánh xạ về cùng một không gian ẩn. Sau đó, một cơ chế *gated multimodal fusion* được sử dụng để học cách kết hợp hai modality này. Ý tưởng của cơ chế gating là mỗi video có thể phụ thuộc vào

hình ảnh hoặc văn bản ở mức độ khác nhau; do đó mô hình không nên luôn coi các modality là quan trọng như nhau.

3. Huấn luyện đa nhiệm vụ kết hợp distillation

Mô hình student được tối ưu theo nhiều tín hiệu đồng thời. Hàm mất mát tổng quát được mô tả như sau:

$$L = L_{ECR} + \lambda_1 L_{aesthetic} + \lambda_2 L_{technical} + \lambda_3 L_{KD} \quad (1)$$

trong đó:

- L_{ECR} là sai số của nhiệm vụ chính, dự kiến sử dụng MSE trên nhãn ECR;
- $L_{aesthetic}$ và $L_{technical}$ là các sai số phụ tương ứng với hai tín hiệu chất lượng do teacher cung cấp;
- L_{KD} là thành phần distillation ở mức biểu diễn, dự kiến sử dụng cosine similarity giữa biểu diễn của student và vector teacher trong không gian đặc trưng.

Các hệ số $\lambda_1, \lambda_2, \lambda_3$ ban đầu có thể được đặt theo giá trị kinh nghiệm và sẽ được hiệu chỉnh thông qua thực nghiệm. Mục tiêu của bước này là kiểm tra xem việc bổ sung tín hiệu phụ và tín hiệu distillation có giúp mô hình học tốt hơn nhiệm vụ chính hay không.

4. Giải thích dự đoán ở mức modality

Để tăng khả năng phân tích, đề tài tích hợp một cơ chế giải thích đơn giản nhưng dễ kiểm chứng. Cụ thể, trong quá trình suy luận, lần lượt triệt tiêu từng luồng đặc trưng (visual hoặc text) và quan sát mức thay đổi của điểm ECR dự đoán. Độ thay đổi này được sử dụng như một chỉ báo về mức đóng góp tương đối của từng modality. Trên cơ sở đó, hệ thống có thể sinh ra một đoạn mô tả ngắn bằng ngôn ngữ tự nhiên để hỗ trợ người dùng diễn giải kết quả.

3. Kế hoạch thực nghiệm và đánh giá

Để đảm bảo tính nghiên cứu, đề tài dự kiến xây dựng các thực nghiệm so sánh theo các nhóm sau:

- **So sánh theo modality:** mô hình chỉ dùng visual embedding, mô hình chỉ dùng text embedding, và mô hình kết hợp visual + text.
- **So sánh theo cơ chế fusion:** nối đặc trưng đơn thuần (*concatenation*) so với *gated fusion*.
- **So sánh theo chiến lược huấn luyện:** chỉ dùng L_{ECR} , dùng đa nhiệm vụ không distillation, và dùng đầy đủ multi-task + distillation.
- **So sánh theo hiệu năng hệ thống:** số tham số, thời gian nội suy và chất lượng dự đoán.

Các chỉ số đánh giá dự kiến bao gồm Pearson correlation, Spearman correlation, MAE, MSE và thời gian nội suy. Ngoài ra, đề tài cũng hướng đến phân tích định tính thông qua các ví dụ dự đoán có giải thích để làm rõ vai trò của từng modality trong các trường hợp cụ thể.

4. Điểm khác biệt của đề tài

Điểm khác biệt mà đề tài hướng đến không nằm ở việc xây dựng một mô hình nền tảng mới, mà ở việc:

- Kết hợp nhiều teacher chuyên biệt để tạo tín hiệu học phù hợp cho bài toán dự đoán engagement;
- Thiết kế một student model gọn nhẹ với cơ chế fusion có khả năng thích nghi theo modality;
- Khảo sát vai trò của chất lọc tri thức trong bối cảnh hồi quy đa phương thức;

- Bổ sung khả năng giải thích ở mức modality cho bài toán dự đoán mức độ thu hút của video.

2.5 Kết quả dự kiến của đề tài

Dựa trên phương pháp đề xuất, đề tài đặt ra các kết quả kỳ vọng như sau:

- **Kết quả định lượng hướng đến:**

- Xây dựng được mô hình student có khả năng dự đoán điểm ECR với mức tương quan dương có ý nghĩa giữa dự đoán và nhãn thực tế trên tập validation có gán nhãn.
- Mục tiêu hướng đến là cải thiện các chỉ số Pearson correlation, Spearman correlation và MAE so với các baseline đơn giản như mô hình chỉ dùng một modality hoặc mô hình fusion theo phép nối đặc trưng thông thường.
- Mục tiêu hướng đến là đạt được một trade-off hợp lý giữa độ chính xác và chi phí tính toán, với mô hình nhẹ hơn đáng kể so với các teacher models.
- Thời gian nội suy của mô hình student, sau khi đã có đặc trưng đầu vào được trích xuất sẵn, được kỳ vọng ở mức đủ nhanh để phục vụ minh họa hoặc triển khai thử nghiệm.

- **Kết quả nghiên cứu hướng đến:**

- Làm rõ mức độ đóng góp của từng thành phần trong mô hình thông qua ablation study, bao gồm:
 - * Vai trò của visual modality,
 - * Vai trò của text modality,
 - * Ảnh hưởng của gated fusion,
 - * Ảnh hưởng của auxiliary tasks,
 - * Ảnh hưởng của KD loss.

- Phân tích xem chất lọc tri thức ở mức biểu diễn có thực sự hỗ trợ cho bài toán hồi quy đa phương thức hay không.
- Đưa ra nhận xét về ưu điểm, hạn chế và khả năng mở rộng của hướng tiếp cận đề xuất.

• **Sản phẩm đầu ra kỹ thuật:**

- Pipeline trích xuất đặc trưng từ video ngắn sử dụng các mô hình teacher đã chọn.
- Bộ dữ liệu trung gian dưới dạng JSON hoặc định dạng tương đương dùng cho huấn luyện student.
- Mã nguồn huấn luyện, đánh giá và suy luận của mô hình student.
- Mô hình tốt nhất sau huấn luyện.
- Mục tiêu hướng đến là có thêm một giao diện demo đơn giản cho phép tải video, hiển thị điểm dự đoán và giải thích ngắn gọn.

• **Kết quả học thuật:**

- Báo cáo khóa luận tốt nghiệp hoàn chỉnh.
- Nếu điều kiện thực nghiệm cho phép, đề tài có thể tiếp tục được phát triển theo hướng hoàn thiện bài báo khoa học hoặc báo cáo hội nghị trong nước.

2.6 Kế hoạch thực hiện

Đề tài dự kiến được thực hiện trong thời gian từ tháng 07/2025 đến tháng 07/2026. Dưới đây là bảng phân công công việc chi tiết cho các thành viên. Trong trường hợp phát sinh giới hạn về thời gian tính toán hoặc tài nguyên GPU, đề tài sẽ ưu tiên hoàn thành pipeline trên một tập dữ liệu con đủ đại diện để phục vụ đánh giá phương pháp, sau đó mở rộng quy mô thực nghiệm nếu điều kiện cho phép.

STT	Thời gian	Nội dung công việc	Người phụ trách
1	07/2025 08/2025	– Khảo sát tài liệu về multimodal learning, knowledge distillation, video engagement prediction; hoàn thiện đề cương nghiên cứu.	Cả hai thành viên
2	09/2025 11/2025	– Chuẩn bị môi trường tính toán, tổ chức phiên bản dữ liệu SnapUGC được sử dụng trong thực nghiệm và kiểm tra tính đầy đủ của metadata và video.	Tuấn Công
3	12/2025	Cài đặt, kiểm thử và chuẩn hóa pipeline cho các teacher models gồm ImageBind, MUSIQ/TOPIQ, BLIP-2 và MiniLM.	Anh Thư
4	01/2026 02/2026	– Trích xuất đặc trưng đa phương thức, lưu dữ liệu trung gian dưới dạng JSON hoặc định dạng tương đương; kiểm tra lỗi và tối ưu thời gian xử lý.	Tuấn Công
5	03/2026	Cài đặt mô hình DistilStudent với cơ chế Gated Fusion; xây dựng hàm mất mát đa nhiệm vụ và thành phần distillation.	Anh Thư
6	04/2026	Huấn luyện mô hình, tinh chỉnh siêu tham số và thực hiện các thực nghiệm baseline ban đầu.	Cả hai thành viên
7	05/2026	Đánh giá mô hình bằng các chỉ số định lượng; thực hiện ablation study và xây dựng mô-đun giải thích dự đoán ở mức modality.	Tuấn Công
8	06/2026	Trực quan hóa kết quả thực nghiệm, phân tích lỗi, hoàn thiện mô-đun suy luận và xây dựng demo minh họa.	Anh Thư
9	07/2026	Viết báo cáo tổng kết, hoàn thiện slide bảo vệ và chuẩn bị tài liệu học thuật liên quan nếu điều kiện cho phép.	Cả hai thành viên

Bảng 1: Bảng kế hoạch thực hiện và phân công nhiệm vụ dự kiến.

Tài liệu

- [1] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.
- [2] A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, and Y. Bengio, “Fitnets: Hints for thin deep nets,” in *International Conference on Learning Representations*, 2015.

- [3] Y. Tian, D. Krishnan, and P. Isola, “Contrastive representation distillation,” in *International Conference on Learning Representations*, 2020.
- [4] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, *et al.*, “Learning transferable visual models from natural language supervision,” in *Proceedings of the 38th International Conference on Machine Learning*, pp. 8748–8763, 2021.
- [5] R. Girdhar, A. El-Nouby, M. Singh, K. V. Alwala, A. Joulin, and I. Misra, “Imagebind: One embedding space to bind them all,” *arXiv preprint arXiv:2305.05665*, 2023.
- [6] Z. Tong, Y. Song, J. Wang, and L. Wang, “Videomae: Masked autoencoders are data-efficient learners for self-supervised video pre-training,” *arXiv preprint arXiv:2203.12602*, 2022.
- [7] J. Li, D. Li, C. Xiong, and S. C. Hoi, “Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation,” in *Proceedings of the 39th International Conference on Machine Learning*, pp. 12888–12900, 2022.
- [8] J. Li, D. Li, S. Savarese, and S. C. Hoi, “Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models,” *arXiv preprint arXiv:2301.12597*, 2023.
- [9] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pp. 3982–3992, 2019.
- [10] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, “Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers,” *arXiv preprint arXiv:2002.10957*, 2020.

- [11] J. Ke, Q. Wang, Y. Wang, P. Milanfar, and F. Yang, “Musiq: Multi-scale image quality transformer,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 5148–5157, 2021.
- [12] C. Chen, J. Mo, J. Hou, H. Sun, L. Liao, W. Lin, H. Li, *et al.*, “Topiq: A top-down approach from semantics to distortions for image quality assessment,” *arXiv preprint arXiv:2308.03060*, 2023.
- [13] S. Bosse, D. Maniry, K.-R. Müller, T. Wiegand, and W. Samek, “Deep neural networks for no-reference and full-reference image quality assessment,” *IEEE Transactions on Image Processing*, vol. 27, no. 1, pp. 206–219, 2018.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [15] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, “Multimodal machine learning: A survey and taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2018.
- [16] A. Acien, A. Morales, J. Fierrez, and R. Vera-Rodriguez, “A survey of multimodal sentiment analysis,” *IEEE Access*, vol. 10, pp. 20517–20539, 2022.
- [17] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 618–626, 2017.
- [18] W. Samek, T. Wiegand, and K.-R. Müller, “Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models,” *arXiv preprint arXiv:1708.08296*, 2017.

- [19] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [20] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” *International Conference on Learning Representations*, 2021.
- [21] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT*, pp. 4171–4186, 2019.
- [22] M. E. Akpınar and J. Berger, “Predicting the popularity of online content,” *Journal of Marketing Research*, vol. 54, no. 2, pp. 282–297, 2017.
- [23] T. Trzciński and P. Rokita, “Learning to predict social media popularity with deep temporal context networks,” in *Proceedings of the 24th ACM International Conference on Information and Knowledge Management*, pp. 1001–1010, 2015.
- [24] H. de Vries, F. Strub, S. Chandar, O. Pietquin, H. Larochelle, and A. Courville, “Modulating early visual processing by language,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [25] J. Arevalo, T. Solorio, M. Montes-y Gómez, and F. A. González, “Gated multimodal units for information fusion,” *arXiv preprint arXiv:1702.01992*, 2017.
- [26] A. Zadeh, M. Chen, S. Poria, E. Cambria, and L.-P. Morency, “Tensor fusion network for multimodal sentiment analysis,” in *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pp. 1103–1114, 2017.

- [27] Y.-H. H. Tsai, S. Bai, P. P. Liang, J. Z. Kolter, L.-P. Morency, and R. Salakhutdinov, “Multimodal transformer for unaligned multimodal language sequences,” in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pp. 6558–6569, 2019.
- [28] J. Wu, X. Sun, S. Xu, *et al.*, “A survey on video action recognition in deep learning,” *Neurocomputing*, vol. 423, pp. 458–476, 2021.
- [29] M. Cheng, Y. Zhang, N. J. Yuan, *et al.*, “Short video recommendation in social media: A survey,” *arXiv preprint arXiv:2201.03529*, 2022.
- [30] Cisco, “Cisco annual internet report,” *Cisco Report*, 2024. Online report.
- [31] Meta AI, “Imagebind: Holistic ai learning and embeddings.” <https://github.com/facebookresearch/ImageBind>, 2023. Accessed: 2026-03-11.
- [32] C. Chen and Contributors, “pyiqa: Python toolbox for image quality assessment.” <https://github.com/chaofengc/IQA-PyTorch>, 2023. Accessed: 2026-03-11.
- [33] N. Reimers and Contributors, “Sentence-transformers: Multilingual sentence, paragraph, and image embeddings.” <https://www.sbert.net/>, 2019. Accessed: 2026-03-11.
- [34] Hugging Face, “Blip image captioning models.” <https://huggingface.co/Salesforce/blip-image-captioning-base>, 2024. Accessed: 2026-03-11.
- [35] Kaggle, “Snapugc dataset.” <https://www.kaggle.com/>, 2025. Dataset page used in this project, Accessed: 2026-03-11.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 16 tháng 3 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)